

# Función Generadora de Momentos y Varianza

*Nexus-Probability*

## CURSO 1 (PROBABILIDAD I)

PARTE 5 / LECCIÓN 3

### 1. Introducción

En teoría de probabilidad y procesos estocásticos, las funciones generadoras son herramientas matemáticas que permiten analizar y caracterizar distribuciones de probabilidad. Entre las funciones generadoras más utilizadas se encuentran la función generadora de momentos y la función generadora de probabilidad.

### 2. Función Generadora de Momentos

La función generadora de momentos (FGM) de una variable aleatoria  $X$  es definida como:

$$M_X(t) = E[e^{tX}]$$

siempre que la esperanza exista en un entorno de  $t = 0$ . Esta función es útil porque permite obtener los momentos de la variable aleatoria de la siguiente manera:

$$E[X^n] = M_X^{(n)}(0)$$

es decir, derivando la función generadora de momentos  $n$  veces y evaluando en  $t = 0$ , se obtienen los momentos de la variable aleatoria.

### 3. Función Generadora de Probabilidad

La función generadora de probabilidad (FGP) de una variable aleatoria discreta  $X$  se define como:

$$G_X(s) = E[s^X] = \sum_{k=0}^{\infty} P(X = k)s^k$$

para valores de  $s$  dentro de un radio de convergencia apropiado. Esta función es útil en el estudio de procesos estocásticos, especialmente en cadenas de Markov y procesos de ramificación.

## 4. Principales Variables Aleatorias y sus Funciones Generadoras

### Distribución Bernoulli

- Definición: Una variable aleatoria  $X$  sigue una distribución Bernoulli con parámetro  $p$  si toma valores 1 con probabilidad  $p$  y 0 con probabilidad  $1 - p$ .

- FGM:

$$M_X(t) = (1 - p) + pe^t$$

- FGP:

$$G_X(s) = (1 - p) + ps$$

### Distribución Binomial

- Definición: Una variable aleatoria  $X$  sigue una distribución Binomial  $B(n, p)$  si representa el número de éxitos en  $n$  ensayos de Bernoulli independientes.

- FGM:

$$M_X(t) = (1 - p + pe^t)^n$$

- FGP:

$$G_X(s) = (1 - p + ps)^n$$

### Distribución Poisson

- Definición: Una variable aleatoria  $X$  sigue una distribución Poisson con parámetro  $\lambda$  si representa el número de eventos en un intervalo de tiempo fijo con tasa promedio  $\lambda$ .

- FGM:

$$M_X(t) = e^{\lambda(e^t - 1)}$$

- FGP:

$$G_X(s) = e^{\lambda(s - 1)}$$

### Distribución Normal

- Definición: Una variable aleatoria  $X$  sigue una distribución Normal con media  $\mu$  y varianza  $\sigma^2$ , denotada como  $N(\mu, \sigma^2)$ .

- FGM:

$$M_X(t) = e^{\mu t + \frac{1}{2}\sigma^2 t^2}$$

## Distribución Exponencial

- Definición: Una variable aleatoria  $X$  sigue una distribución Exponencial con parámetro  $\lambda$  si modela el tiempo entre eventos en un proceso de Poisson.

- FGM:

$$M_X(t) = \frac{\lambda}{\lambda - t}, \quad \text{para } t < \lambda$$

**Ejercicio 1** *Una fábrica recibe pedidos de productos a una tasa media de 5 pedidos por hora, siguiendo una distribución de Poisson. Usa la función generadora de momentos para determinar:*

- *La media y la varianza de los pedidos por hora.*
- *La probabilidad de recibir exactamente 7 pedidos en una hora.*
- *Simula 1000 muestras de la cantidad de pedidos en Python y compara los valores empíricos con los teóricos.*

Este ejercicio analiza un proceso de Poisson, que modela la llegada de eventos en un intervalo de tiempo.

- La media y la varianza de una distribución Poisson con parámetro  $\lambda$  son ambas iguales a  $\lambda$ .
- Se usa la función generadora de momentos (FGM) para derivar estos valores.
- Se calcula la probabilidad de recibir exactamente 7 pedidos usando la función de masa de probabilidad (PMF).
- Finalmente, se simulan 1000 muestras para comparar los resultados teóricos con valores empíricos.

```

1 import numpy as np
2 import scipy.stats as stats
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 from scipy.special import factorial
6
7 # Ejercicio 1: Distribución Poisson y la FGM
8 lambda_poisson = 5
9 mean_poisson = lambda_poisson

```

```

10 var_poisson = lambda_poisson
11
12 prob_7_pedidos = (lambda_poisson**7 * np.exp(-lambda_poisson)) /
    factorial(7)
13
14 samples_poisson = np.random.poisson(lambda_poisson, 1000)
15 empirical_mean = np.mean(samples_poisson)
16 empirical_var = np.var(samples_poisson)

```

**Ejercicio 2** *Un casino ofrece un juego donde un jugador tiene una probabilidad del 40 % de ganar en cada intento. Si juega 10 veces:*

- *Usa la función generadora de probabilidad para determinar la media y la varianza de las ganancias.*
- *¿Cuál es la probabilidad de que gane exactamente 6 veces?*
- *Simula 5000 repeticiones del juego y compara con la distribución teórica.*

Este ejercicio trata sobre un juego de azar con ensayos de Bernoulli repetidos.

- Se usa la función generadora de probabilidad (FGP) para encontrar la media y varianza de una distribución binomial.
- Se calcula la probabilidad de ganar exactamente 6 veces utilizando la PMF de la binomial.
- Se simulan 5000 juegos para comparar los resultados empíricos con los teóricos.

```

1
2 # Ejercicio 2: Distribución Binomial y la FGP
3 n, p = 10, 0.4
4 mean_binomial, var_binomial = n * p, n * p * (1 - p)
5 prob_6_wins = stats.binom.pmf(6, n, p)
6 samples_binomial = np.random.binomial(n, p, 5000)
7 empirical_mean_binomial, empirical_var_binomial = np.mean(
    samples_binomial), np.var(samples_binomial)

```

**Ejercicio 3** *El tiempo entre llegadas de clientes a un restaurante sigue una distribución exponencial con una media de 2 minutos.*

- Usa la función generadora de momentos para encontrar la varianza.
- Determina la probabilidad de que el siguiente cliente tarde más de 5 minutos en llegar.
- Simula 10000 llegadas y verifica la distribución empírica.

Este ejercicio modela tiempos de espera entre llegadas de clientes, siguiendo una distribución exponencial.

- Se usa la FGM para calcular la varianza de la distribución exponencial.
- Se determina la probabilidad de esperar más de 5 minutos usando la función de distribución acumulada (CDF).
- Se simulan 10000 muestras para comparar la distribución empírica con la teórica.

```
1 # Ejercicio 3: Distribución Exponencial y la FGM
2 lambda_exp = 1/2
3 var_exp = 1 / lambda_exp**2
4 prob_more_5 = 1 - stats.expon.cdf(5, scale=1/lambda_exp)
5 samples_exp = np.random.exponential(1/lambda_exp, 10000)
6 empirical_var_exp = np.var(samples_exp)
```

**Ejercicio 4** *Supón que los tiempos de espera de dos cajeros siguen distribuciones exponenciales independientes con parámetros  $\lambda_1 = 1$  y  $\lambda_2 = 2$ .*

- Usa la función generadora de momentos para encontrar la distribución de la suma de los tiempos de espera.
- Simula 5000 sumas de estos tiempos de espera y compáralos con la distribución teórica.

Aquí se estudia la suma de dos variables aleatorias exponenciales independientes.

- Se usa la FGM para analizar la distribución de la suma de tiempos de espera.
- Se simulan 5000 valores de la suma de dos tiempos de espera y se comparan con la distribución teórica.

```

1 # Ejercicio 4: Suma de Variables Exponenciales
2 lambda_1, lambda_2 = 1, 2
3 samples_sum = np.random.exponential(1/lambda_1, 5000) + np.
    random.exponential(1/lambda_2, 5000)

```

**Ejercicio 5** *Si una variable aleatoria  $X$  sigue una distribución normal con media 10 y varianza 4:*

- *Usa la función generadora de momentos para verificar que la media y la varianza son correctas.*
- *Genera 10000 valores aleatorios en Python y compara los momentos empíricos con los teóricos.*

Este ejercicio verifica propiedades de la distribución normal mediante su FGM.

- Se usa la FGM para verificar la media y varianza teóricas.
- Se generan 10000 valores aleatorios y se comparan los momentos empíricos con los teóricos.

```

1 # Ejercicio 5: Distribución Normal y la FGM
2 mu_normal, sigma_normal = 10, 2
3 samples_normal = np.random.normal(mu_normal, sigma_normal,
    10000)
4 empirical_mean_normal, empirical_var_normal = np.mean(
    samples_normal), np.var(samples_normal)

```